

Reconnaître les expressions du visage

Du CNN à YOLO : photos et vidéo

PAN Florianne - SHAO Junjie

FER-2013 : 7 expressions en 48×48

28 709

images
d'entraînement

7 178

images de test

48×48

pixels, niveaux de gris

7

classes

Les classes sont très inégales : **happy** a 7 215 images, **disgust** seulement 436. L'entraînement est découpé en 80 % pour apprendre et 20 % pour valider. Le test sert seulement à l'évaluation finale.

Du réseau simple au CNN

MLP de référence

Flatten → Dense 128 → Softmax 7

36 %

accuracy de validation

CNN

3 blocs Conv + MaxPooling (32, 64, 128 filtres) →

Flatten → Dense 128 → Softmax 7. 683 527


paramètres.

53 %

accuracy de validation

Le CNN atteint 96 % sur l'entraînement mais 53 % sur la validation : c'est du **surapprentissage**.

Architecture du CNN en détail



683 527

paramètres au total, dont 589 952 dans la couche Dense 128

Évaluation du CNN de base sur le test

Expression	Recall
happy	74 %
surprise	59 %
neutral	52 %
disgust	52 %
angry	42 %
fear	41 %
sad	36 %

Accuracy sur le test : **52,5 %**.

Les expressions marquées (sourire, bouche ouverte) sont les mieux reconnues.

Confusions fréquentes : **sad** avec neutral, **fear** avec surprise.


Plusieurs erreurs sûres d'elles (probabilité 1,00) viennent de labels discutables.

Un seul changement à la fois

Expérience	Modification	Acc. validation
E0	CNN de base	53,0 %
E1	+ Early Stopping	53,4 %
E2	+ Dropout 0,5	52,8 %
E3	+ Data Augmentation	56,1 %
E4	+ poids de classes	51,7 %
E5	MobileNetV2 + fine-tuning	51,9 %

E3 est choisi avec la validation. La Data Augmentation fait disparaître presque tout le surapprentissage. Les poids de classes font passer le recall de disgust de 5 % à 74 %, mais coûtent de l'accuracy.

Architecture du CNN retenu



683 527

paramètres au total, dont 589 952 dans la couche Dense 128

Dropout 0,5

après la Dense 128, pour limiter le surapprentissage

Augmentation

retournement, rotation $\approx \pm 14^\circ$, zoom 10 %
: à l'entraînement seulement

Plusieurs visages avec YOLO, puis la vidéo



Réglages

Score de confiance minimum : 0,4. NMS avec un IoU de 0,5 pour garder une seule boîte par visage.

Résultats

5 photos : tous les visages trouvés (scores de 0,80 à 0,89). Photo de groupe souriante : 4 visages sur 4 prédits happy. Les visages sérieux sont surtout prédits neutral, avec des probabilités basses. Vidéo : 80 visages analysés, 78 prédits happy.

Bilan

56,6 % sur le test, pour 7 classes

La baseline a donné 36%. FER-2013 est connu pour être difficile.

Limites

Labels bruités, expressions proches, une seule étiquette par image, petit CNN sur du 48×48, disgust très rare.

Pistes

Plus de données, un transfer learning mieux adapté, un YOLO ajusté sur nos visages.

Merci pour votre attention.